

LumaPath-RL 推荐系统架构与安全评估

面向启发式学习的约束分层决策系统

文档类型：技术架构与数学规格

适用平台：macOS / iOS

当前版本：Lumap 0.1.0 MVP 基线

目标系统：LumaPath-RL 离线训练与受控上线架构

编译方式：Tectonic (XeTeX)

日期：2026 年 9 月 30 日

状态声明。当前可运行 MVP 使用本地确定性推荐、手动方法选择与规则回退；尚未训练、部署或在线调用强化学习策略。本文将已经运行的产品基线与目标推荐系统严格分开，所有 POMDP、离线强化学习、反事实评估和灰度发布内容均为后续工程规格。

摘要

Lumap 的推荐问题不是单步内容排序，而是在用户目标、知识状态、时间预算、可访问性、设备能力与授权持续变化的条件下，选择下一项学习活动并积累可验证证据。本文给出 LumaPath-RL 的目标架构：首页发现采用带硬约束的 contextual slate bandit，Learning Studio 采用 belief-state POMDP/SMDP，并将层级动作拆为学习意图、概念、方法、剂量和具体内容。系统以长期掌握、延迟保持、迁移、自主性和目标进展为奖励，以年龄适宜性、隐私授权、认知负荷、内容安全及用户明确选择为独立 CMDP 成本约束。训练流程采用监督知识状态建模、twin critics、Conservative Q-Learning、行为约束 actor、constraint critics 与拉格朗日乘子；上线前使用 IPS、SNIPS、DR、WDR、有效样本量和 bootstrap 置信区间执行反事实评估。本文同时定义数据合同、可观测性、硬门槛、回滚条件和当前 MVP 到目标系统的分阶段路径。

关键词：自适应学习；POMDP；CMDP；Offline RL；CQL；知识追踪；OPE；安全推荐

目录

1	范围、原则与实现状态	1
1.1	产品目标	1
1.2	当前 MVP 与目标架构	1
1.3	系统不优化的代理指标	1
2	总体系统架构	2
2.1	在线请求边界	2
3	形式化问题：POMDP、SMDP 与 CMDP	2
3.1	部分可观测学习过程	2
3.2	学习者状态与不确定性	2
3.3	受约束决策	3
4	候选生成、硬约束与层级策略	3
4.1	硬约束候选集	3
4.2	首页 slate bandit	3
4.3	Learning Studio 分层策略	4
5	奖励、成本与时间归因	4
5.1	学习奖励	4
5.2	潜势塑形	4
5.3	约束成本	6
6	状态建模与监督预训练	6
6.1	多任务状态损失	6
6.2	缺失与选择偏差	6
7	Offline RL 目标与损失函数	6

7.1	行为策略与支持集	6
7.2	Twin critic 与 Conservative Q-Learning	7
7.3	行为约束 actor	7
7.4	Constraint critics 与拉格朗日优化	7
7.5	联合训练目标	8
8	反事实评估 (OPE)	10
8.1	记号与权重	10
8.2	IPS 与 SNIPS	10
8.3	Doubly Robust 与 Weighted DR	10
8.4	有效样本量与覆盖度	11
8.5	Bootstrap 置信区间	11
9	安全上线门槛与回滚	11
9.1	硬门槛	11
9.2	分阶段发布	12
9.3	在线停止条件	14
10	决策合同、日志与解释	14
10.1	输入输出合同	14
10.2	推荐解释	15
10.3	可删除性与重新计算	15
11	冷启动、探索与异常情况	15
11.1	冷启动	15
11.2	用户覆盖与策略学习	15
11.3	常见异常	16
12	验证计划与阶段路线	16
12.1	阶段划分	16
12.2	最低测试矩阵	16
13	结论	17
A	符号表	17
B	模型卡与发布清单	17

1 范围、原则与实现状态

1.1 产品目标

LumaPath-RL 的优化对象是“下一步学习决策”，而不是页面停留时长或内容消费量。每次决策必须同时满足：

- 1. 尊重用户当前明确输入；用户主动目标的优先级高于画像推断。
- 2. 在证据不足时表达不确定性，并允许用户跳过、固定或屏蔽方法。
- 3. 让理论理解、实践能力、延迟保持与知识迁移分别形成证据。
- 4. 把安全与隐私作为不可由高奖励抵消的约束。
- 5. 在模型不可用、结果过期或动作非法时，确定性回退仍能完成学习闭环。

1.2 当前 MVP 与目标架构

表 1 实现状态边界

范围	当前可运行 MVP	LumaPath-RL 目标架构
首页推荐	三批本地确定性候选；兴趣信号影响首项；支持换一批	安全 contextual slate bandit，记录完整 slate 和 propensity
Studio 调度	17 种学习方法可见；用户手动切换；部分场景为规则推荐	belief-state POMDP/SMDP，分层选择概念、方法、剂量与内容
学习者状态	SwiftData 保存目标、会话、活动结果与部分偏好	带不确定性的知识、保持、负荷、投入、偏好与证据质量联合状态
模型训练	未训练 RL 策略	监督状态预训练 + offline RL + constraint critics
反事实评估	未部署 OPE 管线	IPS/SNIPS/DR/WDR、ESS、覆盖度与分群置信区间
在线发布	规则路径直接运行	影子、可回滚小流量、守门放量；非法决策客户端拒绝
失败路径	本地规则和手动选择可继续工作	版本化 heuristic fallback，策略服务不直接写业务数据库

本文后续以 **Current** 标识已运行基线，以 **Target** 标识待实现能力。演示账户的无限额度是计费权益，不进入状态、奖励、排序、学习效果或 OPE 分群。

1.3 系统不优化的代理指标

以下量不能单独作为正奖励：点击率、连续使用天数、会话时长、完成页数、互动次数、社交来源数量。这些量容易鼓励成瘾式交互、简单题重复或过度打扰。它们可以作为诊断特征，但只有与可比较的学习证据、用户目标和延迟结果共同解释时才参与建模。

2 总体系统架构

Figure 1 将当前本地闭环与目标推荐平面放在同一数据流中。目标策略只返回一个有版本、有时效、可验证的 RecommendationDecision；客户端仍拥有权限检查、业务写入和回退控制权。

2.1 在线请求边界

客户端从本地可信数据构造最小化快照，不上传原始浏览记录、完整社交内容或 API 密钥。请求携带 profileEpoch、goalRevision、consentRevision、候选目录版本及请求截止时间。响应必须同时满足：版本未过期、动作仍属于候选集、hard mask 仍为真、目标版本一致。任何一项失败都拒绝写入，并选择相同输入下可复现的规则动作。

3 形式化问题：POMDP、SMDP 与 CMDP

3.1 部分可观测学习过程

Learning Studio 被建模为折扣 POMDP：

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{O}, T, Z, R, \gamma \rangle, \quad (1)$$

其中 $s_t \in \mathcal{S}$ 是不可直接观测的真实学习状态， $a_t \in \mathcal{A}$ 是学习活动， $o_{t+1} \in \mathcal{O}$ 是答题、讲解、练习、延迟测验或用户反馈产生的观测， $T(s' | s, a)$ 为状态转移， $Z(o | s', a)$ 为观测模型， R 为学习收益， $\gamma \in (0, 1)$ 为跨时间折扣。

历史 $h_t = (o_0, a_0, \dots, a_{t-1}, o_t)$ 被压缩为信念状态

$$b_t(s) = \mathbb{P}(s_t = s | h_t), \quad (2)$$

其 Bayes 更新为

$$b_{t+1}(s') = \eta Z(o_{t+1} | s', a_t) \sum_{s \in \mathcal{S}} T(s' | s, a_t) b_t(s), \quad \eta^{-1} = \sum_{\bar{s}} Z(o_{t+1} | \bar{s}, a_t) \sum_s T(\bar{s} | s, a_t) b_t(s). \quad (3)$$

工程实现不枚举离散状态，而由状态编码器 f_ϕ 近似：

$$\mathbf{b}_t = f_\phi(\mathbf{b}_{t-1}, a_{t-1}, o_t, \Delta t_t, \mathbf{x}_t), \quad (4)$$

其中 $\mathbf{x}_t$ 只包含 allowlist 特征， Δt_t 表示距上一次学习或检测的时间。

学习活动时长不等，因此采用 SMDP 折扣。若动作 a_t 持续 Δ_t 个标准时间单位，则

$$Q^\pi(b_t, a_t) = \mathbb{E}[r_t + \gamma^{\Delta_t} \mathbb{E}_{a_{t+1} \sim \pi(\cdot | b_{t+1})} Q^\pi(b_{t+1}, a_{t+1})]. \quad (5)$$

3.2 学习者状态与不确定性

目标状态向量分解为

$$\mathbf{b}_t = [\mathbf{k}_t, \mathbf{u}_t, \mathbf{h}_t, e_t, \mathbf{p}_t, g_t, f_t, q_t, \mathbf{c}_t, \mathbf{v}_t], \quad (6)$$

其中 $\mathbf{k}_t$ 为概念掌握， $\mathbf{u}_t$ 为不确定性， $\mathbf{h}_t$ 为 24 小时与 7 天保持预测， e_t 为投入状态， $\mathbf{p}_t$ 为方法效果与显式偏好， g_t 为当前目标， f_t 为疲劳/负荷， q_t 为证据质量， $\mathbf{c}_t$ 为设备与无障碍能力， $\mathbf{v}_t$ 为授权版本及数据有效性。

概念 j 的掌握可用 Beta 后验表达：

$$K_{tj} \sim \text{Beta}(\alpha_{tj}, \beta_{tj}), \quad (7)$$

$$\hat{m}_{tj} = \mathbb{E}[K_{tj}] = \frac{\alpha_{tj}}{\alpha_{tj} + \beta_{tj}}, \quad (8)$$

$$u_{tj} = \text{Var}(K_{tj}) = \frac{\alpha_{tj}\beta_{tj}}{(\alpha_{tj} + \beta_{tj})^2(\alpha_{tj} + \beta_{tj} + 1)}. \quad (9)$$

缺失检测不会写成失败分数；不可比量规不会更新同一个 K_{tj} 。主观喜好与学习效果使用不同特征头，避免把“喜欢某方法”等同于“该方法提高掌握”。

3.3 受约束决策

安全问题建模为 CMDP。令决策 t 之前的累计活动时长为 $D_t = \sum_{u=0}^{t-1} \Delta_u$ 且 $D_0 = 0$ 。策略在优化学习回报时，必须同时满足 J_{C_j} 的独立成本预算：

$$\max_{\pi} \quad J_R(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right], \quad (10)$$

$$\text{s.t.} \quad J_{C_j}(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t c_t^{(j)} \right] \leq d_j, \quad j = 1, \dots, J. \quad (11)$$

成本维度至少包括：年龄/内容安全违规、撤销授权后的数据使用、超出认知负荷、无障碍能力不匹配、频繁打扰以及违背用户固定/屏蔽选择。对逻辑上不可接受的动作先执行 hard mask；CMDP 只处理仍合法但存在累积风险的动作。

4 候选生成、硬约束与层级策略

4.1 硬约束候选集

令候选生成器给出 $\mathcal{A}_t^{\text{cand}}$ ，硬规则向量为 $M_t(a) \in \{0, 1\}$ ，则合法集合为

$$\mathcal{A}_{\text{legal}}(b_t) = \left\{ a \in \mathcal{A}_t^{\text{cand}} : M_t(a) = 1 \right\}. \quad (12)$$

掩码至少检查：当前明确目标、内容年龄分级、来源授权、设备 renderer、无障碍、用户屏蔽、方法固定、预计时长和前置条件。对任意策略 logits $z_{\theta}(a | b)$ ，部署分布为

$$\tilde{\pi}_{\theta}(a | b) = \frac{\exp z_{\theta}(a | b) \mathbb{I}[a \in \mathcal{A}_{\text{legal}}(b)]}{\sum_{a' \in \mathcal{A}_{\text{legal}}(b)} \exp z_{\theta}(a' | b)}. \quad (13)$$

若 $\mathcal{A}_{\text{legal}}(b) = \emptyset$ ，系统不让神经策略放宽约束，而是返回 `noEligibleAction`，由客户端给出手动选择或安全的本地说明活动。

4.2 首页 slate bandit

首页一次展示 K 个学习方向，动作为有序 slate $A = (a_1, \dots, a_K)$ 。定义合法动作的有序无重复 K -排列集合

$$\mathfrak{S}_K(\mathcal{A}_{\text{legal}}(x_t)) = \left\{ (a_1, \dots, a_K) \in \mathcal{A}_{\text{legal}}(x_t)^K : a_i \neq a_j \text{ for all } i \neq j \right\}. \quad (14)$$

在上下文 x_t 下，目标为

$$A_t^* = \arg \max_{A \in \mathfrak{S}_K(\mathcal{A}_{\text{legal}}(x_t))} \left[\sum_{k=1}^K u_{\omega}(a_k, x_t) + \lambda_{\text{div}} D(A) - \lambda_{\text{rep}} H(A, \mathcal{E}_t) \right], \quad (15)$$

其中 $D(A)$ 奖励主题多样性， H 惩罚与近期曝光集 $\mathcal{E}_t$ 的重复。“不感兴趣，换一批”仅对当前曝光项产生短期负反馈，不外推成对整个领域的永久厌恶。

4.3 Learning Studio 分层策略

活动写成五元组

$$a_t = (g_t, c_t, m_t, d_t, x_t), \quad (16)$$

其中 g 是学习意图， c 是概念， m 是方法， d 是剂量/时长， x 是具体内容实例。联合策略按层分解：

$$\begin{aligned} \pi_{\theta}(a_t | b_t) &= \pi_{\theta_G}(g_t, c_t | b_t) \\ &\quad \cdot \pi_{\theta_M}(m_t, d_t | b_t, g_t, c_t) \\ &\quad \cdot \pi_{\theta_X}(x_t | b_t, g_t, c_t, m_t, d_t). \end{aligned} \quad (17)$$

每一层分别归一化并记录 propensity，联合 propensity 是各层条件概率之积。这样既能解释“为什么先补这个概念”，也能解释“为什么此时用模拟而不是讲解”。

5 奖励、成本与时间归因

5.1 学习奖励

即时奖励使用经量规和证据质量归一化的分量：

$$\begin{aligned} r_t^{\text{learn}} &= w_M \Delta M_t + w_{24} R_{t+24h} + w_7 R_{t+7d} + w_T T_t + w_A A_t + w_G \Delta G_t \\ &\quad - w_F F_t - w_O O_t - w_D D_t - w_H H_t, \end{aligned} \quad (18)$$

其中 ΔM 为同量规掌握增益， R_{24} , R_7 为延迟保持， T 为新情境迁移， A 为自主性， ΔG 为明确目标进展； F 为挫败， O 为过载， D 为无效重复， H 为提示依赖。权重先由教育目标与用户研究设定，再在离线敏感性分析中检查，不由点击最大化反推。

当延迟结果尚未到达时，事件保持 **pending**，不能把缺失写成零。训练数据用 outcome window 和审查截止时间区分 pending、observed、expired 与 declined。令 $D_{t,k} = \sum_{u=0}^{k-1} \Delta_{t+u}$ 且 $D_{t,0} = 0$ ，跨步归因可采用时长感知的 n 步回报：

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^{D_{t,k}} r_{t+k} + \gamma^{D_{t,n}} V(b_{t+n}). \quad (19)$$

5.2 潜势塑形

为提升稀疏奖励下的训练稳定性，只采用保持最优策略不变的潜势塑形：

$$r'_t = r_t + \gamma^{\Delta t} \Phi(b_{t+1}) - \Phi(b_t), \quad (20)$$

其中 Φ 只能使用当前合法、已授权的学习进展特征。不能把付费状态、无限额度、社交数量或使用时长放入 Φ ，否则会改变产品目标并产生不可解释激励。


Current: 可运行本地闭环

图 1 当前产品闭环与目标 LumaPath-RL 推荐平面。蓝色为目标能力，灰色为当前 MVP；推荐服务不绕过客户端的硬约束和持久化边界。




图 2 层级策略与 belief 更新闭环。安全掩码位于策略之前，客户端验证位于执行之前；用户覆盖被记录为选择，而不是学习失败。

5.3 约束成本

hard mask 处理“绝不允许”的动作；soft constraint critic 处理跨步累积风险。示例成本为

$$c_t^{\text{load}} = \max(0, \hat{f}_{t+1} - f_{\max}), \quad (21)$$

$$c_t^{\text{interrupt}} = \mathbb{I}[\text{nudge within quiet window}], \quad (22)$$

$$c_t^{\text{access}} = \mathbb{I}[\text{required capability unavailable}], \quad (23)$$

$$c_t^{\text{privacy}} = \mathbb{I}[\text{evidence revision invalid}]. \quad (24)$$

隐私和内容安全在正常设计中应被 hard mask 消除；若观察到非零成本，视为系统缺陷并触发停止发布，而不是让拉格朗日优化“权衡”它们。

6 状态建模与监督预训练

6.1 多任务状态损失

在进行 RL 之前，先使用可解释的监督目标训练和校准状态编码器。定义

$$\begin{aligned} \mathcal{L}_{\text{state}} = & \lambda_{\text{KT}} \text{BCE}(y^{\text{mastery}}, \hat{p}^{\text{mastery}}) + \lambda_{\text{RET}} \text{BCE}(y^{\text{ret}}, \hat{p}^{\text{ret}}) \\ & + \lambda_{\text{TIME}} \text{Huber}(y^{\text{time}}, \hat{t}) + \lambda_{\text{HINT}} \text{BCE}(y^{\text{hint}}, \hat{p}^{\text{hint}}) \\ & + \lambda_{\text{LOAD}} \text{Huber}(y^{\text{load}}, \hat{f}) + \lambda_{\text{CAL}} \text{Brier}(\hat{p}, y). \end{aligned} \quad (25)$$

所有标签携带量规版本、题族、辅助条件和证据质量。不同题族、不同辅助或不同难度的结果不通过固定扣分强行“校正”为同一标签。校准报告至少包含 Brier score、ECE、分年龄组可靠性图和置信区间。

6.2 缺失与选择偏差

检测是可选的，缺失机制通常不是完全随机。训练集必须保留 m_t^{observed} 、检测邀请、接受/跳过、提醒曝光与退出原因。可以用逆参与概率作敏感性分析，但不把其结果包装成因果结论。自选方法数据标为 observational；只有经过明确同意、条件可比的随机或交替安排才能支持更强的方法效果估计。

7 Offline RL 目标与损失函数

7.1 行为策略与支持集

日志数据集为

$$\mathcal{D} = \left\{ (b_t, a_t, r_t, c_t, b_{t+1}, \mu_t, \mathcal{A}_t^{\text{cand}}, M_t, v_t) \right\}, \quad (26)$$

其中 $\mu_t = \mu(a_t | b_t)$ 是日志策略 propensity, v_t 是所有相关版本。缺失完整候选、mask 或 propensity 的旧日志只能用于状态模型和描述统计，不能进入正式 OPE。

7.2 Twin critic 与 Conservative Q-Learning

令 $Q_{\theta_1}, Q_{\theta_2}$ 为 twin reward critics，目标值使用较小者抑制过估计：

$$y_t^Q = r_t + \gamma^{\Delta_t} \mathbb{E}_{a' \sim \tilde{\pi}_\psi(\cdot | b_{t+1})} \left[\min_{i \in \{1,2\}} Q_{\theta_i}(b_{t+1}, a') - \tau \log \tilde{\pi}_\psi(a' | b_{t+1}) \right], \quad (27)$$

$$\mathcal{L}_{\text{TD}}^{(i)} = \frac{1}{2} \mathbb{E}_{(b,a,r,b') \sim \mathcal{D}} \left[Q_{\theta_i}(b, a) - y_t^Q \right]^2. \quad (28)$$

对每个 critic，CQL 正则只在当时合法候选上计算：

$$\mathcal{L}_{\text{CQL}}^{(i)} = \mathcal{L}_{\text{TD}}^{(i)} + \alpha \mathbb{E}_{b \sim \mathcal{D}} \left[\log \sum_{a \in \mathcal{A}_{\text{legal}}(b)} \exp Q_{\theta_i}(b, a) - \mathbb{E}_{a \sim \mu(\cdot | b)} Q_{\theta_i}(b, a) \right]. \quad (29)$$

第二项压低日志支持之外动作的虚高价值。若 action support 过窄，正确处理是收集受控数据或缩小策略改进范围，而不是仅提高 α 后直接上线。

7.3 行为约束 actor

行为模型 $\hat{\mu}_\xi(a | b)$ 由日志动作监督训练：

$$\mathcal{L}_{\text{behavior}}(\xi) = -\mathbb{E}_{(b,a) \sim \mathcal{D}} \log \hat{\mu}_\xi(a | b). \quad (30)$$

actor 使用悲观价值、行为约束和熵正则：

$$\begin{aligned} \mathcal{L}_{\text{actor}}(\psi) = & -\mathbb{E}_{b \sim \mathcal{D}, a \sim \tilde{\pi}_\psi} \left[\min_i Q_{\theta_i}(b, a) \right] \\ & + \beta \mathbb{E}_{b \sim \mathcal{D}} \text{KL}(\tilde{\pi}_\psi(\cdot | b) \| \hat{\mu}_\xi(\cdot | b)) - \tau \mathbb{E}_{b \sim \mathcal{D}} \mathcal{H}(\tilde{\pi}_\psi(\cdot | b)). \end{aligned} \quad (31)$$

分层策略的监督一致性项为

$$\mathcal{L}_{\text{hier}} = -\mathbb{E}_{\mathcal{D}} [\log \pi_G(g, c | b) + \log \pi_M(m, d | b, g, c) + \log \pi_X(x | b, g, c, m, d)]. \quad (32)$$

7.4 Constraint critics 与拉格朗日优化

每个成本维度 j 有 twin constraint critics $Q_{\omega_{j,1}}^{C_j}, Q_{\omega_{j,2}}^{C_j}$ ：

$$y_t^{C_j} = c_t^{(j)} + \gamma^{\Delta_t} \mathbb{E}_{a' \sim \tilde{\pi}_\psi} \left[\max_{k \in \{1,2\}} Q_{\omega_{j,k}}^{C_j}(b_{t+1}, a') \right], \quad (33)$$

$$\mathcal{L}_{C_j}^{(k)} = \frac{1}{2} \mathbb{E}_{\mathcal{D}} \left[Q_{\omega_{j,k}}^{C_j}(b_t, a_t) - y_t^{C_j} \right]^2. \quad (34)$$

成本采用较大 critic 形成保守上界。拉格朗日 actor 为

$$\mathcal{L}_{\text{actor}}^{\text{safe}} = \mathcal{L}_{\text{actor}} + \sum_{j=1}^J \lambda_j \left(\mathbb{E}_{b \sim \mathcal{D}, a \sim \tilde{\pi}_\psi} \left[\max_k Q_{\omega_{j,k}}^{C_j}(b, a) \right] - d_j \right), \quad (35)$$


$$\lambda_j \leftarrow \left[\lambda_j + \eta_\lambda \left(\hat{J}_{C_j} - d_j \right) \right]_+, \quad \lambda_j \geq 0. \quad (36)$$

7.5 联合训练目标

在阶段式训练中，各项不是从第一步同时打开。最终联合目标写为

$$\begin{aligned} \mathcal{L}_{\text{total}} = & \mathcal{L}_{\text{state}} + \lambda_Q \sum_{i=1}^2 \mathcal{L}_{\text{CQL}}^{(i)} + \lambda_{\pi} \mathcal{L}_{\text{actor}}^{\text{safe}} + \lambda_C \sum_{j=1}^J \sum_{k=1}^2 \mathcal{L}_{C_j}^{(k)} \\ & + \lambda_H \mathcal{L}_{\text{hier}} + \lambda_{\text{fair}} \mathcal{L}_{\text{group}} + \lambda_{\text{expl}} \mathcal{L}_{\text{explanation}}. \end{aligned} \quad (37)$$

其中公平性项只检查同等合法候选和相近任务条件下的最差组退化；解释项约束输出理由必须引用真正参与决策的特征。它们不能替代分群 OPE、用户控制或上线守门。[Equation \(37\)](#) 是训练阶段与权重的汇总记号，不表示对所有参数执行一次联合最小化。状态编码器、行为模型、reward critics、constraint critics 与 actor 使用独立优化器和独立验证早停；target critics 停止梯度并采用慢速更新。actor 固定 critic 参数执行下降，而 λ_j 按 [Equation \(36\)](#) 对约束违例执行 dual ascent，避免错误地把拉格朗日乘子当作普通损失参数共同下降。



门槛语义：OPE 或压力审计不通过时，当前模型停止于本阶段；团队缩小策略改进范围、修正规格或收集受控数据后创建新的数据集与训练版本，不在同一流水线内回写或绕过门槛。注册 artifact 绑定 feature schema、candidate catalog、reward/cost 版本、训练数据哈希、评估报告和回滚目标。

图 3 目标离线训练流水线。每个阶段产生可审计产物；未通过 OPE 的模型不能进入注册候选。

8 反事实评估 (OPE)

8.1 记号与权重

对第 i 条轨迹 τ_i ，日志策略为 μ ，待评估策略为 π 。单步比率及累积比率为

$$\rho_{i,t} = \frac{\pi(a_{i,t} | b_{i,t})}{\mu(a_{i,t} | b_{i,t})}, \quad (38)$$

$$w_{i,0:t} = \prod_{k=0}^t \rho_{i,k}, \quad \bar{w}_{i,0:t} = \min(w_{i,0:t}, w_{\max}), \quad \bar{w}_i := \bar{w}_{i,0:T_i-1}. \quad (39)$$

OPE 的 positivity/overlap 条件必须对评估分布中的每个 belief 成立：

$$\text{supp}(\pi(\cdot | b)) \subseteq \text{supp}(\mu(\cdot | b)), \quad b \sim d_{\pi}^{\text{eval}}. \quad (40)$$

只检查已经被日志选中的动作是否有 $\mu > 0$ 并不足够；必须检查目标策略赋予正概率的全部动作是否有日志支持。裁剪降低方差但引入偏差，报告必须同时给出未裁剪诊断、裁剪阈值和敏感性分析。

8.2 IPS 与 SNIPS

若第 i 条轨迹包含 T_i 个决策、总回报为 G_i ，轨迹级 IPS 和自归一化 SNIPS 为

$$\hat{V}_{\text{IPS}}(\pi) = \frac{1}{N} \sum_{i=1}^N \bar{w}_i G_i, \quad (41)$$

$$\hat{V}_{\text{SNIPS}}(\pi) = \frac{\sum_{i=1}^N \bar{w}_i G_i}{\sum_{i=1}^N \bar{w}_i}. \quad (42)$$

首页 slate 的 propensity 必须是实际展示 slate 的联合概率或有理论依据的分解概率，不能用单卡点击概率代替。

8.3 Doubly Robust 与 Weighted DR

单步 contextual bandit 的 DR 估计为

$$\hat{V}_{\text{DR}} = \frac{1}{N} \sum_{i=1}^N \left[\hat{q}(b_i, \pi) + \rho_i(r_i - \hat{Q}(b_i, a_i)) \right], \quad \hat{q}(b, \pi) = \sum_a \pi(a | b) \hat{Q}(b, a). \quad (43)$$

对长会话，定义归一化累积权重与累计活动时长

$$\tilde{w}_{i,t} = \frac{\bar{w}_{i,0:t}}{\sum_{j=1}^N \bar{w}_{j,0:t}}, \quad \tilde{w}_{i,-1} = \frac{1}{N}, \quad (44)$$

$$D_{i,0} = 0, \quad D_{i,t} = \sum_{k=0}^{t-1} \Delta_{i,k}. \quad (45)$$

则有限时域 Weighted Doubly Robust 估计为

$$\begin{aligned} \hat{V}_{\text{WDR}} = & \sum_{i=1}^N \tilde{w}_{i,-1} \hat{V}(b_{i,0}) \\ & + \sum_{t=0}^{T-1} \sum_{i=1}^N \gamma^{D_{i,t}} \tilde{w}_{i,t} \left[r_{i,t} + \gamma^{\Delta_{i,t}} \hat{V}(b_{i,t+1}) - \hat{Q}(b_{i,t}, a_{i,t}) \right]. \end{aligned} \quad (46)$$

WDR 同时依赖 propensity 与价值模型；二者的误设风险不同，因此报告必须并列 IPS、SNIPS、DR 与 WDR，不能只选择最有利的估计量。

8.4 有效样本量与覆盖度

重要性权重的有效样本量为

$$\text{ESS}_t = \frac{\left(\sum_{i=1}^N \bar{w}_{i,0:t}\right)^2}{\sum_{i=1}^N \bar{w}_{i,0:t}^2}. \quad (47)$$

同时报告最大权重、权重分位数、合法动作覆盖率

$$\text{Coverage}(\pi; \mathcal{D}) = \mathbb{E}_{b \sim \mathcal{D}} \left[\sum_{a: N_{\mathcal{D}}(b,a) \geq n_{\min}} \pi(a | b) \right], \quad (48)$$

以及各关键 cohort 的覆盖。高点估计配合低 ESS 不能获得上线资格。

8.5 Bootstrap 置信区间

按用户而不是按单条交互进行 cluster bootstrap，以保留同一学习者轨迹内相关性。对估计量 $\hat{\Delta} = \hat{V}(\pi) - \hat{V}(\pi_0)$ ，从用户簇有放回采样 B 次，得到

$$\text{CI}_{1-\alpha}(\Delta) = \left[\hat{\Delta}^{*(\alpha/2)}, \hat{\Delta}^{*(1-\alpha/2)} \right]. \quad (49)$$

延迟保持结果按 outcome window 截止；不能让尚未到期的 pending 样本在候选策略与基线间产生不同缺失处理。

9 安全上线门槛与回滚

9.1 硬门槛

设 π_0 为当前版本化规则或已上线策略，候选为 π_1 。进入影子模式前必须同时满足：

$$\text{LCB}_{1-\alpha}(V_R(\pi_1) - V_R(\pi_0)) \geq -\delta_R, \quad (50)$$

$$\text{UCB}_{1-\alpha}(J_{C_j}(\pi_1)) \leq d_j, \quad \forall j, \quad (51)$$

$$\min_{g \in \mathcal{G}} \text{LCB}_{1-\alpha}(V_R^g(\pi_1) - V_R^g(\pi_0)) \geq -\delta_g, \quad (52)$$

$$\min_{g \in \mathcal{G}} \text{ESS}_g \geq E_{\min}, \quad \min_{g \in \mathcal{G}} \text{Coverage}_g \geq \kappa_{\min}. \quad (53)$$

此外，schema 合法率、hard-mask 一致率和越权成本必须为 100%；这些门槛不是统计容忍项。以下评估参数必须在评估前写入版本化审批配置，不能看完结果后修改：

$$\delta_R, \quad \delta_g, \quad E_{\min}, \quad \kappa_{\min}. \quad (54)$$

9.2 分阶段发布

表 2 目标发布阶段与退出条件

阶段	允许行为	退出或回滚条件
离线回放	不接触用户；校验决策合同、mask、时延与 fallback	任一非法动作；OPE/ESS/覆盖未达门槛
压力测试	合成缺失、撤权、跨档案、过期响应、分布漂移	旧响应可写入；回退不确定；隐私成本非零
影子模式	生产请求只读推理；用户仍执行基线动作	候选非法率非零；p99 超预算；与基线分歧不可解释
内部 canary	仅团队账户；一键回滚	崩溃、写入错误、负荷或成本阈值触发
自愿小流量	已同意成人 cohort；未成年人默认不探索	学习 LCB、最差组、成本或用户控制任一退化
守门放量	分阶段增加固定流量；保持 holdout	漂移、异常权重、延迟结果反转或审计缺失




图 4 目标上线守门与回滚流程。所有“否”分支均停止放量；回滚不依赖待回滚的策略服务。

9.3 在线停止条件

任一条件触发自动熔断并恢复到已验证基线：

- hard-mask 不一致、跨档案决策、撤销来源仍参与理由或过期响应被接受；
- 安全成本超过预算，或关键 cohort 的上置信界超过预算；
- 最差组学习指标低于预设非劣界，或参与/检测缺失结构发生显著变化；
- 推理超时、空候选、schema 错误或客户端拒绝率超过阈值；
- feature、candidate catalog、reward、policy 与客户端版本组合未在兼容矩阵中；
- 延迟保持结果到达后推翻 canary 期间的即时收益判断。

10 决策合同、日志与解释

10.1 输入输出合同

表 3 核心数据合同

对象	必填字段	约束与用途
LearnerStateSnapshot	profileEpoch、goalRevision、consentRevision、knowledge、uncertainty、retention、fatigue、capabilities	只含 allowlist 特征；每项可追溯到有效来源版本；不含密钥和完整原始社交内容
RecommendationCandidate	candidateID、intent、concept、method、dose、content、requirements、riskClass、renderer	候选目录版本固定；具体内容与 renderer 能力在客户端可验证
RecommendationDecision	action、alternatives、layerPropensities、reasonCodes、policyVersion、expiry、inputDigest	不能直接写 SwiftData；输入摘要用于拒绝过期或错配响应
DecisionEvent	request、完整候选、hardMask、loggingPropensity、decision、outcomeWindows、versions	是 OPE 的最小日志单元；失败、手动覆盖和回退均保留

对象	必填字段	约束与用途
OutcomeEvent	rubricVersion、 evidenceType、quality、 observedAt、status、 sourceEventID	status 区分 pending、observed、 declined、expired、invalidated
PolicyArtifact	modelHash、 featureSchema、 rewardVersion、 costBudgets、 datasetHash、 OPEReport、 fallbackVersion	注册、放量和回滚的不可分割发布 单元

10.2 推荐解释

解释不是让生成模型事后编故事。结构化理由由策略输入与候选约束产生：

$$e_t = \text{Explain} \left(a_t, \mathcal{F}_t^{\text{used}}, \mathcal{C}_t^{\text{active}}, \text{Alt}_t \right), \tag{55}$$

其中 $\mathcal{F}^{\text{used}}$ 是实际进入排序的可见特征， $\mathcal{C}^{\text{active}}$ 是生效约束，Alt 是合法备选。自然语言只负责把 reason code 转成用户语言，不能增加未使用的个人推断。

10.3 可删除性与重新计算

事件维护依赖链

source → evidence → state projection → decision reason → training eligibility.

用户撤销来源时立即递增 `consentRevision`，旧快照和在途响应失效；异步物理删除完成前，相关证据已被排除在查询和推荐之外。若已进入训练数据，后续模型需通过重训练或经验证的数据删除流程处理，并在模型卡中披露删除延迟。

11 冷启动、探索与异常情况

11.1 冷启动

无历史证据时使用版本化规则先验和多样性候选，不伪造“根据你的习惯”。当日志支持充分时，首页可以在合法集合内使用 LinUCB/Thompson sampling；Studio 的安全策略改进可采用 SPIBB 类约束，使低支持状态动作靠近日志基线。未成年人默认不进入探索性在线更新。

11.2 用户覆盖与策略学习

用户手动选项优先。覆盖事件应区分：显式偏好、时间变化、辅助需求、内容错误、只是想尝试其他方式。策略不能将一次覆盖直接解释为长期负奖励。对固定方法或屏蔽方法，hard mask 在下一个决策立刻生效。

11.3 常见异常

表 4 异常处理

异常	在线行为	数据行为
策略超时/不可用	使用同版本 heuristic fallback	记录 timeout 与 fallback，不伪造策略动作
动作不在候选集或被 mask	客户端拒绝；返回手动选择或规则动作	记录 policy defect，禁止该版本放量
目标/授权版本变化	丢弃旧响应，按新快照重算	旧事件标为 stale，不进入 outcome 归因
检测跳过	学习流程继续，状态保持未知	标为 declined，不写零分
延迟结果未到期	不改变即时 UI 结论	标为 pending，OPE 截止时一致处理
无合法候选	显示安全的概览或用户选择	记录 noEligibleAction，检查目录覆盖
分布漂移	降级或冻结学习策略	启动新 cohort 审计与重校准

12 验证计划与阶段路线

12.1 阶段划分

1. **H0**：当前 **MVP**。保持本地确定性推荐与手动模块选择；完善版本、候选曝光、回退和结果日志。
2. **H1**：可评估规则策略。上线统一 Decision Contract，补齐候选、mask、propensity 与 outcome window；建立可重放日志。
3. **H2**：状态模型与影子服务。训练知识追踪、保持和负荷预测；策略仍不改变用户体验，先验证校准和客户端拒绝路径。
4. **H3**：受限离线策略。在支持充分的成人自愿 cohort 内训练 CQL 与 constraint critics，通过独立 OPE 后进入影子。
5. **H4**：可回滚小流量。内部 canary、自愿小流量、延迟结果守门；未成年人继续使用经审核基线。

12.2 最低测试矩阵

- 单元测试：mask 单调性、空集合、层级 propensity 乘积、reward/cost 版本、迟到结果、幂等事件。
- 属性测试：任何被屏蔽动作概率为零；所有返回动作属于候选；版本变化后旧响应永不落库。
- 回放测试：固定快照、目录和策略版本得到同一确定性验证结果；fallback 在断网下可完成。

- OPE 测试：已知合成 MDP 上 IPS/DR 近似真值；错误 propensity、低覆盖和极端权重必须让门槛失败。
- 分群测试：年龄范围、设备能力、学习语言、辅助方式和证据缺失组分别报告，不用总体均值掩盖退化。
- 故障注入：撤销来源、切换档案、快速修改目标、乱序响应、服务超时、模型回滚与客户端旧版本。

13 结论

LumaPath-RL 的核心不是用强化学习取代产品规则，而是在不可妥协的权限、安全与用户选择范围内，对长期学习证据进行保守的策略改进。当前 Lumap MVP 已提供本地学习闭环、17 类学习方法、理论与实践检测、讲解课件和规则回退；它还没有部署 RL 模型。目标系统必须先形成可审计的决策合同和高质量日志，再训练带不确定性的学习者状态，随后使用 CQL 与 constraint critics 做离线优化，最后通过覆盖度、ESS、多估计量 OPE、分群置信区间、影子与小流量门槛逐步发布。任何阶段无法证明安全和非劣性时，继续使用版本化规则策略就是正确结果。

A 符号表

表 5 主要符号

符号	含义
s_t, b_t	真实学习状态与其 belief/编码表示
a_t, o_t	学习活动与活动后观测
μ, π	日志策略与待评估/候选策略
$M_t(a)$	hard mask; 1 表示当时动作合法
$r_t, c_t^{(j)}$	学习奖励与第 j 个安全成本
$Q_\theta, Q_\omega^{C_j}$	reward critic 与 constraint critic
d_j	第 j 个 CMDP 成本预算
$D_t, D_{t,k}$	决策前累计活动时长与从决策 t 起算的局部累计时长
ρ, w	单步 importance ratio 与累积 importance weight
ESS	重要性权重有效样本量
LCB, UCB	下/上置信界
$\mathcal{D}_v$	版本冻结、资格验证后的离线数据集

B 模型卡与发布清单

每个进入模型注册表的 artifact 至少包含：

- feature schema、candidate catalog、mask、reward、cost、rubric 和 outcome-window 版本；
- 训练/验证/OPE 数据哈希、时间范围、纳入/排除规则与删除状态；
- 状态模型校准、CQL gap、行为 KL、各 constraint critic 误差；
- IPS、SNIPS、DR、WDR、ESS、最大权重、覆盖率及 cluster-bootstrap 区间；
- 总体与关键 cohort 的 reward/cost 结果，最差组门槛和未解决限制；
- 延迟、资源占用、schema 合法率、客户端拒绝率和 fallback 命中率；
- 目标客户端版本、发布阶段、审批人、回滚模型与回滚演练结果。

参考文献

- [1] L. P. Kaelbling, M. L. Littman, and A. R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1–2):99–134, 1998.
- [2] A. Kumar, A. Zhou, G. Tucker, and S. Levine. Conservative Q-Learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.
- [3] N. Jiang and L. Li. Doubly robust off-policy value evaluation for reinforcement learning. In *Proceedings of the 33rd International Conference on Machine Learning*, 2016.
- [4] P. Thomas and E. Brunskill. Data-efficient off-policy policy evaluation for reinforcement learning. In *Proceedings of the 33rd International Conference on Machine Learning*, 2016.
- [5] R. Larocche, P. Trichelair, and R. Tachet des Combes. Safe policy improvement with baseline bootstrapping. In *Proceedings of the 36th International Conference on Machine Learning*, 2019.
- [6] A. Y. Ng, D. Harada, and S. Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the 16th International Conference on Machine Learning*, 1999.
- [7] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*, 2nd edition. MIT Press, 2018.